


DeepSeek-V4.1-Flash DGX Spark 4 / 8 机实测

2026-09-11 14:03 北京时间 · SGLang · 原始响应与失败记录完整保留

4/8机SGLang混合注意力方案均完成基础正确性、随机检索与C1-C8测试。C1三次中位decode：4机计数71.04、代码57.92、正文27.37 TPS；8机78.32、67.03、28.58 TPS，提升约4%-16%。8机有效prefill为4机的1.63-1.76倍，C8总吞吐仅约-4%至+4%。单流优先时4机已具备较好的资源效率；8机提供有限的decode增益。



条件	任务	次数	输入/输出 token	最低 TPS	中位 TPS	最高 TPS	TTFT 中位 s
4机 eager B	计数	1	18 / 239	13.99	13.99	13.99	0.285
4机 eager B	代码	1	36 / 200	11.76	11.76	11.76	0.657
4机 eager B	科普正文	1	25 / 129	11.43	11.43	11.43	0.474
4机全 Triton	计数	2	18 / 239	44.37	45.43	46.50	0.322
4机全 Triton	代码	2	36 / 200	35.66	36.10	36.55	0.571
4机全 Triton	科普正文	2	25 / 134	17.30	17.37	17.44	0.451
4机混合	计数	3	18 / 239	70.79	71.04	71.72	0.195
4机混合	代码	3	36 / 200	57.80	57.92	58.43	0.251
4机混合	科普正文	3	25 / 127	26.50	27.37	27.60	0.222
8机混合	计数	3	18 / 239	65.98	78.32	83.22	0.151
8机混合	代码	3	36 / 200	57.10	67.03	68.10	0.213
8机混合	科普正文	3	25 / 128	28.26	28.58	31.76	0.171

同一无标签提示词；temperature=0；thinking关闭。计数上限256、代码/正文上限200输出token。4/8机计数文本一致，代码和正文措辞不同，按实际token数计时。重复提示可命中prefix cache；decode不含TTFT。计数速度不代表自然语言任务。

实验环境与运行配置

项目	实测环境
设备	8台 DGX Spark / GB10; ARM64; SM121; 每节点1个GPU, OS内存约119-122GiB
节点	4机B: .98/.103/.104/.105; 4机A: .99/.100/.101/.102; 8机: 192.168.32.98-105
互联	NCCL两路RoCE: rocep1s0f1 / roceP2p1s0f1, GID5; 主节点两链路实测各100Gb/s, 未测聚合有效带宽
模型	DeepSeek-V4.1-Flash; 48个safetensors分片, 约476GiB; 非Engram分片约286.124GiB
镜像	lmsysorg/sglang:dev-v4f-2dgx-v2; ID 67873eb93b99...; 复用已有镜像
软件	SGLang 0.0.0.dev1+g452239a74 + V4.1 Python/JIT overlay; PyTorch 2.13.0+cu130; CUDA13.0
内核库	FlashInfer0.6.18; Triton3.7.1; Transformers5.12.1; NVIDIA580.142
注意力 / MoE	dsv4 MLA; flashinfer_mxfp4 MoE; 保留checkpoint原始混合精度
存储	完整权重位于 /mnt/beegfs/models/DeepSeek-V4.1-Flash; 优化配置Engram位于各节点/data
复现文件	recover_eager.py; adapter-local-engram/sitecustomize.py; recovery/各轮启动目录中的rank脚本与日志

部署参数

参数	eager基线	全Triton优化	混合优化（4/8机）
并行	TP4 / EP4 / PP1	TP4 / EP4 / PP1	TP=EP=设备数; PP1
注意力	FlashInfer	Triton	Triton prefill / FlashInfer decode
最大运行请求	1	8	8
DSpark	关闭	block size 5	block size 5
CUDA Graph	关闭	decode BS1-8	decode BS1-8
prefill graph	关闭	关闭	关闭
Engram	BeeGFS按需读取	节点本地稀疏副本	节点本地稀疏副本
context / KV	8192 / 8192	8192 / 8192	8192 / 8192
prefill chunk	1024	1024	1024
mem fraction	.85	.85	.85
autotune	关闭	关闭	关闭
加载	顺序读取/复制	所有CPU专家权重clone	所有CPU专家权重clone

容器限制12个CPU核、host memory100GiB; 该限制不能覆盖全部GPU分配。Engram cache全TP合计8GiB。两机未实测; PP/EP解耦及其它并行组合未在本模型本轮测量, 不能填作零性能。

测量标准：prefill 与 decode 分开


指标	定义及解释
C1-C8	同时发出的请求数为1-8，与设备数分开。C8的每流TPS与八机不是同一概念。
单流decode TPS	(服务端usage.completion_tokens-1) / (结束事件时间-首个非空生成事件时间)。结束事件包含EOS；沿用参考测量口径。
多流decode TPS	同一并发批次，各请求单流decode TPS的算术平均。
批次总输出吞吐	该批次全部completion tokens之和 / 从批次开始至全部请求结束的墙钟时间；包含首token等待。
TTFT	客户端发出请求至首次生成内容；包含排队、tokenize、prefill、首decode及网络时间。
有效prefill TPS	输入token数 / 客户端TTFT；输出限制1token。先进行相近形状但不同前缀的预热。不是纯GPU prefill kernel TPS。
SSE与推测解码	使用服务端token计数，不把SSE块数当token数。首块可能多token，减1的参考口径存在小偏差；保留全部事件，2-token短答不纳入速度排名。
缓存与输出	C1重复测试可能命中prefix cache；并发矩阵使用逐请求前置标签。代码200token可按长度截断，完整代码正确性使用独立512token上限。

验收范围

先运行9类基础文本检查和9个输入长度样本，再进行随机记录码检索。并发性能覆盖代码、科普正文和计数三类任务的C1-C8；逐请求保存响应并执行基本内容检查。自动检查覆盖格式与关键答案，不能替代完整质量基准。

服务配置、提示词、输出上限不同的测量分表展示。失败样本、被停止的矩阵与未测条件不进入有效性能排名；已获得的诊断速度仍保留。所有时段使用客户端monotonic计时。


计数：4 / 8 机 C1-C8 对比



设备	并发	每流TPS	总吞吐	TTFT s	输入token	输出token	内容检查
4机	C1	68.08	63.67	0.254	30-30	239-239	通过
4机	C2	61.79	112.96	0.317	30-30	239-239	通过
4机	C3	54.90	147.21	0.487	30-30	239-239	通过
4机	C4	53.68	190.45	0.512	30-30	239-239	通过
4机	C5	51.44	219.47	0.682	30-30	239-239	通过
4机	C6	47.98	246.76	0.709	30-30	239-239	通过
4机	C7	45.29	265.82	0.883	30-30	239-239	通过
4机	C8	41.88	284.16	0.883	30-30	239-239	通过
8机	C1	70.87	67.03	0.205	30-30	239-239	通过
8机	C2	75.23	142.27	0.192	30-30	239-239	通过
8机	C3	68.01	182.27	0.389	30-30	239-239	通过
8机	C4	60.10	216.48	0.367	30-30	239-239	通过
8机	C5	57.81	251.79	0.501	30-30	239-239	通过
8机	C6	47.11	249.77	0.533	30-30	239-239	通过
8机	C7	45.86	280.72	0.664	30-30	239-239	通过
8机	C8	42.14	293.84	0.684	30-30	239-239	通过

表内每格为一次并发批次；C1-C8共36条请求/任务/设备组。曲线未测点不补零。前置唯一标签避免本轮请求复用相同完整提示，与首页无标签C1三次复测分开。


代码：4 / 8 机 C1-C8 对比



设备	并发	每流TPS	总吞吐	TTFT s	输入token	输出token	内容检查
4机	C1	55.70	51.41	0.315	47-47	200-200	通过
4机	C2	48.38	83.79	0.564	47-47	200-200	通过
4机	C3	43.70	103.55	1.067	47-47	200-200	通过
4机	C4	40.48	134.64	0.774	47-47	200-200	通过
4机	C5	36.92	152.86	0.974	47-47	200-200	通过
4机	C6	37.58	186.21	1.117	47-47	200-200	通过
4机	C7	33.18	187.36	1.236	47-47	200-200	通过
4机	C8	31.53	207.87	1.272	47-47	200-200	通过
8机	C1	65.62	60.89	0.250	47-47	200-200	通过
8机	C2	58.82	93.35	0.848	47-47	200-200	通过
8机	C3	47.95	122.46	0.636	47-47	200-200	通过
8机	C4	46.69	164.04	0.583	47-47	200-200	通过
8机	C5	40.14	172.57	0.720	47-47	200-200	通过
8机	C6	41.47	203.55	0.991	47-47	200-200	通过
8机	C7	39.38	226.05	0.977	47-47	200-200	通过
8机	C8	32.39	216.19	1.009	47-47	200-200	通过

表内每格为一次并发批次；C1-C8共36条请求/任务/设备组。曲线未测点不补零。前置唯一标签避免本轮请求复用相同完整提示，与首页无标签C1三次复测分开。


科普正文：4 / 8 机 C1-C8 对比



设备	并发	每流TPS	总吞吐	TTFT s	输入token	输出token	内容检查
4机	C1	24.04	22.96	0.271	36-36	118-118	通过
4机	C2	19.23	36.49	0.398	36-36	121-128	通过
4机	C3	15.91	42.77	0.525	36-36	121-129	通过
4机	C4	17.51	58.62	0.659	36-36	115-121	通过
4机	C5	13.98	57.19	0.808	36-36	112-129	通过
4机	C6	13.67	71.15	0.786	36-36	122-132	通过
4机	C7	13.38	81.36	0.999	36-36	122-131	通过
4机	C8	12.42	87.81	1.009	36-36	121-131	通过
8机	C1	29.83	28.35	0.222	36-36	118-118	通过
8机	C2	21.82	40.01	0.393	36-36	120-120	通过
8机	C3	19.72	55.64	0.410	36-36	124-126	通过
8机	C4	18.57	65.75	0.508	36-36	121-131	通过
8机	C5	16.38	72.70	0.698	36-36	119-130	通过
8机	C6	15.69	79.21	0.696	36-36	117-136	通过
8机	C7	14.75	87.99	0.728	36-36	116-128	通过
8机	C8	12.02	84.21	0.737	36-36	121-138	通过

表内每格为一次并发批次；C1-C8共36条请求/任务/设备组。曲线未测点不补零。前置唯一标签避免本轮请求复用相同完整提示，与首页无标签C1三次复测分开。

输入处理：TTFT、有效 prefill 与检索



配置	实际输入token	TTFT s	有效prefill TPS
4机 eager/BeeGFS	2950	33.990	86.8
4机 eager/BeeGFS	5853	65.154	89.8
4机混合/本地	2950	11.502	256.5
4机混合/本地	5853	23.141	252.9
8机混合/本地	2950	7.062	417.7
8机混合/本地	5853	13.182	444.0

独立上下文检索检查

配置	输入token	TTFT s (独立请求)	随机记录码匹配
4机 eager	1502	30.611	通过
4机 eager	2922	31.823	通过
4机 eager	5914	66.049	通过
4机混合	1502	6.791	通过
4机混合	2922	11.809	通过
4机混合	5914	23.626	通过
8机混合	1502	3.974	通过
8机混合	2922	6.612	通过
8机混合	5914	13.729	通过

随机记录码位于填充文本中部，验证实际上下文读取。检索TTFT包含冷缓存/首次形状影响，与上方预热后prefill分开。两组差异同时包含存储、图、推测解码和注意力配置，不能仅归因于某一项优化。

文本正确性与失败样本

样本	输入token	eager	全Triton	4机混合	8机混合
coding	36	通过	通过	通过	通过
json	54	通过	通过	通过	通过
narrative	28	通过	通过	通过	通过
prose	25	通过	通过	通过	通过
math	59	通过	通过	通过	通过
reasoning	53	通过	通过	通过	通过
summary	292	未通过	通过	通过	通过
format	74	通过	通过	通过	通过
ceiling_count	18	通过	通过	通过	通过
length_sweep_0	20	通过	通过	通过	通过
length_sweep_8	55	通过	通过	通过	通过
length_sweep_16	87	通过	通过	通过	通过
length_sweep_24	119	通过	通过	通过	通过
length_sweep_32	151	通过	通过	通过	通过
length_sweep_48	215	通过	通过	通过	通过
length_sweep_64	279	通过	通过	通过	通过
length_sweep_128	535	通过	通过	通过	通过
length_sweep_256	1047	通过	通过	通过	通过

代码检查验证语法及函数名；JSON检查字段和数组数量；数学/表格检查关键答案；摘要检查三条要点及主题词。计数逐项核对1-80。长度扫描只问法国首都，不能单独证明长上下文质量；另有随机记录码检索。

FlashInfer 诊断边界

原全FlashInfer优化配置的短计数最高72.72 TPS，但带标签JSON、摘要和表格出现无关输出，矩阵在C2停止。eager也在无标签摘要上失败，但同一组带标签提示通过。全Triton及混合配置通过基础任务后才进入性能测试。现有证据不能简单归结为“所有长提示失败”或单一DSpark错误。

参考方案的迁移价值与诊断记录

参考仓库固定在 [ca662ac35193c69ace9cee37f13a94abf2eff0fc](#)。其中Spark内存约束、本地Engram行副本、编译并行限制、DSpark与CUDA Graph设置对SGLang有参考价值；vLLM与SGLang算子/API不同，不能直接复制运行结果。

参考方向	本轮SGLang实现与证据
Engram本地化	按TP rank创建稀疏本地副本；TP4约47.21GiB/节点，TP8约23.60GiB/节点；每份8008行抽检全部一致。
行读取与图回放	原生reader CPU检查536项；2层×6种长度×3次新ID图回放逐位一致。稀疏文件只供reader，不作为完整checkpoint。
推测解码与图	DSpark block5；精确decode BS1-8。target/draft图均完成；prefill graph关闭。
注意力兼容	当前FlashInfer0.6.18；参考vLLM仓库采用较新的固定提交。混合方案用Triton接管prefill并保留FlashInfer decode；不直接搬运不同API的二进制。
权重加载	单文件线程、顺序GPU复制、所有CPU专家权重clone；避免无界future持有mmap权重。不同物理组加载对照不是单变量推理性能实验。

未通过完整验收的 FlashInfer 优化速度（保留诊断）


任务	次数	最低TPS	中位TPS	最高TPS
计数	3	60.00	65.89	72.72
代码	3	48.44	57.95	59.41
科普正文	3	19.20	27.43	28.02

原异常矩阵每流 TPS

任务	C1	C2	C3	C4	C5	C6	C7	C8
coding	56.39	32.04	-	-	-	-	-	-
json	14.15	41.86	-	-	-	-	-	-
narrative	18.45	-	-	-	-	-	-	-
prose	22.66	-	-	-	-	-	-	-
math	49.24	-	-	-	-	-	-	-
reasoning	31.78	-	-	-	-	-	-	-
summary	22.16	-	-	-	-	-	-	-
format	67.92	-	-	-	-	-	-	-
ceiling_count	68.60	-	-	-	-	-	-	-

该页诊断速度不纳入有效配置排名。外部仓库的TPS没有并入本机实测；报告不包含RTX性能数据。

追加实测：SGLang FlashInfer 0.7 与 vLLM 4/8机单流




运行时	设备	并行	计数TPS	代码TPS	正文TPS
SGLang 0.6.18	4	TP4/EP4/PP1	71.04	57.92	27.37
SGLang + FlashInfer 0.7	4	TP4/EP4/PP1	77.66	58.17	16.86
vLLM + FlashInfer 0.7	4	TP4/EP4/PP1	91.98	75.54	30.79
vLLM + FlashInfer 0.7	8	TP8/EP8/PP1	108.03	83.24	37.53

FlashInfer 0.7 的SGLang修复让计数单流由71.04升至77.66 tok/s，代码基本持平。固定最终轮正文为16.86 tok/s；同一服务的其它持续流量对照达到30.16 tok/s，日志显示DSpark草稿接受率随提示显著变化，因此正文波动不能直接归因于attention kernel。vLLM四机为91.98/75.54/30.79，八机提升到108.03/83.24/37.53 tok/s。

单流decode不含TTFT；服务端usage计token，从首个内容token计至EOS。计数、代码、正文分别展示，不用计数上限代替一般任务速度。

追加实测：C8、prefill 与八机内存边界



配置	C8计数	C8代码	C8正文
SGL 0.6 / 4机	284.16	207.87	87.81
SGL 0.7 / 4机	281.51	204.97	77.25
vLLM / 4机	341.26	237.45	95.55
vLLM / 8机	364.37	273.91	103.38

配置	2950-token prefill TPS	5853-token prefill TPS
SGL 0.6 / 4机	256.5	252.9
SGL 0.7 / 4机	347.6	351.2
vLLM / 4机	1502.7	1664.4
vLLM / 8机	1461.6	1685.3

vLLM八机C8为364.37/273.91/103.38 tok/s；相对四机只提升6.8%/15.4%/8.2%。prefill为1461.6/1685.3 tok/s，与四机1502.7/1664.4基本持平。TP8增加的跨机collective抵消了单rank计算缩小；日志还明确显示world size 8下FlashInfer all-reduce被禁用。

vLLM首次以gpu-memory-utilization=0.80启动时，每节点KV预算约39GiB，FlashInfer自动调优申请临时工作区时触发驱动NV_ERR_NO_MEMORY。改为0.65后每节点可用KV约21.06GiB、总KV约4,103,718 token，仍可支持约13.68个300k请求并顺利完成C1-C8。

有效prefill为prompt_tokens / 客户端TTFT，包含调度、网络 and 首token，不是纯kernel数值。SGLang 0.7两档shape显式预热；vLLM沿用四机对照的不预热协议。

原始 eager A / B 实测记录

条件	并行	输入token	输出token	TTFT s	decode TPS
4机A 计数	TP4/EP4/PP1	18	239	0.282	11.73
4机A 代码	TP4/EP4/PP1	36	200	0.610	11.60
4机A 正文	TP4/EP4/PP1	25	129	0.469	10.98
4机B 计数	TP4/EP4/PP1	18	239	0.285	13.99
4机B 代码	TP4/EP4/PP1	36	200	0.657	11.76
4机B 正文	TP4/EP4/PP1	25	129	0.474	11.43

A组使用.99/.100/.101/.102；B组使用.98/.103/.104/.105。两组均为eager、无DSpark、BeeGFS Engram、最大并发1。A对CPU权重视图clone；B对全部CPU专家权重clone。三个提示词输出逐字相同；代码在200token上限截断。

两个物理节点组不同，加载开始时刻和GPU状态也不同。因此A/B差异不能证明clone补丁改变推理速度。扩大验证后，A的无标签摘要出现无关输出；同一组带标签JSON、摘要和表格又通过，异常样本完整保留。

该表保留本轮最初六条实测，不以优化结果替换旧数据。仅这三个短提示的正常输出不能代表全部任务验收。对应原始目录：bench/20260911-014732-spark4-eager-a 与 bench/20260911-014733-spark4-eager-b。

历次部署尝试与启动证据


实验	配置/变化	主权重加载	结果
2机	本模型未测	-	没有实测容量或吞吐结论
4机初始	大上下文/DSpark	-	加载未完成，未获得推理结果
8机首次	源码不齐	282-336s	JIT缺少n128k512.cuh
8机补齐源码	自动KV/多模态warmup	296-320s	图捕获完成并开放8108；图像预热时未就绪
4机恢复初始	异步加载	-	专家copy_等待，主动停止
4机 A	顺序复制；视图 clone	rank0 778.38 s	正确生成；计数/代码/正文已测
4机 B	顺序复制；全部 CPU 专家权重 clone	rank0 575.50 s	正确生成；计数/代码/正文已测
4机 B 优化	本地 Engram；DSpark5；decode full graphs	主601.06s； draft148.41s	完整任务集出现无关输出，停止矩阵；性能待正确性验收
4机 T	本地Engram；DSpark5；graphs；全 Triton MLA	主575.52s	9类基础检查通过；输出长度条件分别记录
4机混合	本地Engram；DSpark5；graphs；Triton prefill / FlashInfer decode	主577.62s； draft153.87s	基础任务、随机检索、C1-C8内容检查通过
8机混合	本地Engram；DSpark5；graphs；Triton prefill / FlashInfer decode	主250.93-337.94s； draft7.78-72.24s	基础检查/随机检索/C1-C8全部通过

重启事件复核

完整日志证明旧8机的target/draft CUDA Graph均完成，2026-09-10 23:57:34已开放HTTP 8108；不能据旧的片段记录断言SM121图捕获失败。后续图像预热窗口伴随NVIDIA NV_ERR_NO_MEMORY与驱动rw-semaphore等待。旧KV full池28,719,616 token，本轮硬限制8192并跳过自动图像预热。

加载秒数来自各rank日志，不包含完整启动/JIT/预热时间；未完成记录不补造数据。所有旧日志与此次逐轮命令均归档。

GPU 状态与多机性能波动



观察	结论边界
无推理请求、模型驻留时，.101/.102出现55-80GB/s GEMV片段；其余约220-239GB/s	单GPU微基准，不能当作模型decode TPS。慢rank可能拖累多机同步，但未与历史4/8差异做因果对照。
.101快慢片段频率中位数同为2405MHz、温度63°C、throttle flags为0	不支持简单归因于固定低频或过热；功耗中位数分别约30.05W/20.94W。
卸载模型后，.101两轮GEMV中位数225-229GB/s	未复现慢态；不能区分内存驻留、驱动状态、负载历史。未修改时钟、电源或固件。

8机连续单流计数复测：仅采集NVML，无额外GPU计算

轮次	decode TPS	各节点时钟中位 MHz	各节点功耗中位均值 W	限频标志	计数检查
1	69.64	2398-2411	26.49	0	通过
2	86.15	2392-2411	30.41	0	通过
3	85.34	2392-2411	30.60	0	通过
4	85.99	2392-2411	30.65	0	通过
5	84.80	2392-2411	30.76	0	通过
6	85.47	2392-2411	30.80	0	通过

6次连续复用同一计数提示，与首页交错三任务协议分开。采样按客户端接收时间对齐decode时段；快慢样本的时钟接近、限频标志均0，不能据此认定固定低频。功耗与速度相关，但因果方向未确定。

原始数据与复现索引

内容	文件/目录（工作区根目录下）
本轮原始目录	experiments/spark-dsv41-20260910/recovery/
完整测试链	suite-*/manifest.json：步骤、退出码、校验来源；失败任务保留error
C1重复样本	bench/*/summary.json及各请求JSON；完整SSE、usage、文本、TTFT、decode时长
C1-C8与prefill	matrix-20260911/bench-*.json；raw-*为逐请求响应
正确性/检索	correctness-*/results.json；retrieval-*/results.json
命令与加载日志	YYYYMMDD-HHMMSS/rank*.sh；config及原容器日志；archived-*
Engram验证	local-engram-tp4-*、local-engram-tp8-*；engram-graph-parity.log
GPU与波动	gpu-state-20260911-*；jitter-*/summary.json及按客户端时间对齐的NVML采样
启动器/测试脚本	recover_eager.py；finish_spark_bench.py；bench_matrix.py；bench_c1_reference.py
数据索引	recovery/report-data-index.json：报告读取的配置和矩阵路径

复现与适用范围

本报告为DeepSeek-V4.1-Flash专项实验，不将历史Qwen或其它DeepSeek版本数据混入。测试最大上下文/KV为8192，不代表更长上下文、视觉请求或生产质量验收。模型文件总量包含按需读取的Engram，不能仅凭476GiB文件体积推断双机部署是否可能。

.98系统时钟曾比控制端慢约44分16秒；所有请求性能采用客户端monotonic计时，跨节点日志墙钟不直接相减。完整报告中的缺失项用“-”，没有以0 TPS替代未测或失败。

来源：[tonyd2wild / Spark vLLM配方](#)；[0xSero / V4.1 SGLang源码适配参考](#)。报告只引用后者的实现思路，不引用其RTX性能。